

Beyin Tümörü Tespiti ve Sınıflandırması İçin Derin Öğrenme Yaklaşımları

Özet

Bu çalışmada, beyin Manyetik Rezonans (MR) görüntülerini kullanılarak beyin tümörlerinin otomatik tespiti ve sınıflandırılması amacıyla yüksek başarılı bir derin öğrenme sistemi geliştirilmiştir. Proje kapsamında, "glioma", "meningioma", "hipofiz (pituitary)" tümörleri ve "tümörsüz (notumor)" olmak üzere dört farklı sınıfın ayrıştırılması hedeflenmiştir. Model geliştirme aşamasında üç farklı yaklaşım karşılaştırılmış olarak uygulanmıştır: (1) Sıfırdan eğitilen klasik bir Evrişimli Sinir Ağı (CNN) mimarisi, (2) EfficientNetB6 mimarisi kullanılarak gerçekleştirilen Transfer Öğrenme (Transfer Learning) yöntemi ve (3) Keras Tuner kullanılarak hiperparametre optimizasyonu yapılmış özelleştirilmiş bir CNN modeli.

Yapılan deneysel çalışmalar sonucunda, EfficientNetB6 tabanlı Transfer Learning modeli %92.22 test başarımı ile en başarılı model olmuştur.

Geliştirilen en iyi model, gerçek dünya senaryolarında kullanılabilirliğini göstermek amacıyla FastAPI ve React kullanılarak modern bir web uygulamasına entegre edilmiştir.

I. GİRİŞ

Beyin tümörleri, kafatası içerisindeki hücrelerin kontrolsüz ve anormal büyümesi sonucu oluşan, hayatı risk taşıyan ciddi sağlık problemlerinden biridir. Dünya Sağlık Örgütü (WHO) verilerine göre, beyin tümörlerinin erken ve doğru teşhisini, tedavi planlamasının başarısı ve hastanın yaşam kalitesi üzerinde kritik bir role sahiptir. Günümüzde bu teşhis süreci, genellikle radyologların Manyetik Rezonans (MR) görüntülerini manuel olarak incelemesine dayanmaktadır. Ancak bu süreç zaman alıcıdır, uzmanlık gerektirir ve insan faktöründen kaynaklı hatalara açık olabilir. Bu bağlamda, yapay zeka ve özellikle derin öğrenme (Deep Learning) teknikleri, tıbbi görüntülerin analizinde radyologlara yardımcı olabilecek güçlü araçlar olarak önemli bir rol oynamaktadır.

Bu projenin temel amacı, beyin MR görüntülerini analiz ederek tümör varlığını tespit eden ve varsa tümörün türünü (Glioma, Meningioma, Hipofiz) yüksek doğrulukla sınıflandıran bir yapay zeka sistemi geliştirmektir. Proje kapsamında literatürde yaygın olarak kullanılan ve başarısı kanıtlanmış farklı derin öğrenme stratejileri ele alınmıştır.

İlk aşamada, temel bir Evrişimli Sinir Ağı (CNN) mimarisi tasarlanmış ve veri seti üzerinde sıfırdan eğitilmiştir. İkinci aşamada, daha az veri ile daha yüksek başarı elde etmek ve eğitim süresini kısaltmak amacıyla Transfer Learning (Transfer Öğrenme) yöntemi uygulanmıştır. Bu kapsamda,

ImageNet veri seti üzerinde önceden eğitilmiş olan ve son teknoloji (State-of-the-Art) mimarilerden biri olan EfficientNetB6 modeli kullanılarak ince ayar (fine-tuning) işlemleri gerçekleştirilmiştir. Üçüncü aşamada ise, modelin performansını maksimize etmek için Keras Tuner kütüphanesi kullanılmış; katman sayısı, filtre boyutları, dropout oranları ve öğrenme katsayı (learning rate) gibi hiperparametreler otomatik olarak optimize edilmiştir.

Modelin sadece teorik bir çalışma olarak kalmaması ve pratik bir uygulamaya dönmesi amacıyla, geliştirilen model bir web servisi olarak dışa açılmıştır. Python tabanlı FastAPI kullanılarak, modelin tahmin yapmasını sağlayan hızlı ve asenkron bir API geliştirilmiştir. Son kullanıcıların sisteme kolayca erişebilmesi için ise React ile modern bir kullanıcı arayüzü tasarlanmıştır. Bu arayüz üzerinden yüklenen görüntüler, API aracılığıyla modele iletilmekte ve teşhis sonucu olasılık değerleriyle birlikte ekrana yansıtılmaktadır.

II. MATERİYAL VE YÖNTEM

A. Veri Seti (Dataset)

Çalışmada, beyin tümörü tespiti için açık kaynaklı bir Manyetik Rezonans (MR) görüntü veri seti kullanılmıştır. Veri seti, dört farklı sınıfı temsil eden toplam 7.037 adet beyin MR görüntüsünden oluşmaktadır.

• Sınıflar:

- Glioma:** Beyin ve omurilikteki glial hücrelerden kaynaklanan tümörler.
- Meningioma:** Beyin ve omuriliği çevreleyen zarlardan (meninksler) kaynaklanan tümörler.
- Pituitary (Hipofiz):** Hipofiz bezinde oluşan tümörler.
- No Tumor (Tümörsüz):** Sağlıklı beyin görüntüleri.

Veri seti, modelin genelleme yeteneğini artırmak ve aşırı öğrenmeyi (overfitting) önlemek amacıyla Eğitim (Training), Doğrulama (Validation) ve Test (Testing) olmak üzere üç alt kümeye ayrılmıştır:

- Eğitim Seti:** Modelin ağırlıklarını güncellemek için kullanılan görüntüler (%80).
- Doğrulama Seti:** Eğitim sırasında modelin performansını izlemek ve hiperparametreleri ayarlamak için kullanılan görüntüler (%20).
- Test Seti:** Modelin daha önce hiç görmemişti veriler üzerindeki nihai başarısını ölçmek için ayrılan görüntüler.

Veri seti kaynağı:

<https://www.kaggle.com/datasets/masoudnickparvar/brain-tumor-mri-dataset>

Görüntüler modele verilmeden önce **224x224 piksel** boyutlarına yeniden boyutlandırılmış (resizing) ve piksel değerleri 0-1 aralığına normalize edilmiştir (rescaling). Ayrıca, veri setini zenginleştirmek ve modelin farklı varyasyonlara karşı dayanıklılığını artırmak için **Veri Çoğaltma (Data Augmentation)** teknikleri (döndürme, kaydırma, yakınlaştırma, yatay çevirme) uygulanmıştır.

B. Kullanılan Teknolojiler ve Araçlar

Projenin geliştirilmesinde aşağıdaki yazılım ve kütüphaneler kullanılmıştır:

- **Programlama Dili:** Python 3.13.1
- **Derin Öğrenme Kütüphaneleri:** TensorFlow, Keras
- **Veri İşleme ve Görselleştirme:** NumPy, Pandas, Matplotlib, Seaborn
- **Hiperparametre Optimizasyonu:** Keras Tuner
- **API Geliştirme:** FastAPI, Uvicorn
- **Geliştirme Ortamı:** Google Colab (Eğitim için), VS Code (API için)
- **Donanım:** Model eğitimi, Google Colab üzerindeki **NVIDIA T4 GPU** kullanılarak hızlandırılmıştır.

C. Veri Ön İşleme ve Hazırlık (Data Preprocessing)

Ham veri seti, model eğitimi hale getirilmek için çok aşamalı bir ön işleme hattından (pipeline) geçirilmiştir. Bu aşamalar, geliştirilen modelin türüne (Klasik CNN veya Transfer Learning) göre farklılık göstermektedir.

1. **Veri Yükleme ve Etiketleme:** Eğitim ve Test klasörlerindeki görüntüler pathlib kütüphanesi ile taranmış, dosya yolları (filepaths) ve sınıf etiketleri (labels) çıkarılarak bir Pandas DataFrame yapısında birleştirilmiştir. Bu işlem verinin yönetilebilirliğini artırmıştır.
2. **Veri Bölme (Stratified Splitting):** Modelin eğitim sırasında her sınıfın dengeli örnek görmesini sağlamak amacıyla, Eğitim seti kendi içinde %80 Eğitim ve %20 Doğrulama (Validation) olarak ayrılmıştır. Bu ayrim sırasında sklearn kütüphanesinin `train_test_split` fonksiyonu stratify parametresi ile kullanılarak, sınıf dağılıminin (label distribution) her iki alt kümeye de orantılı olması garanti edilmiştir.
3. **Görüntü İşleme ve Artırma (Data Augmentation):** Modelin genellemeye yeteneğini artırmak için ImageDataGenerator kullanılarak gerçek zamanlı veri çoğaltma uygulanmıştır.

• Klasik CNN ve Keras Tuner Modelleri İçin:

- **Renk Modu:** Hesaplama maliyetini düşürmek ve yapısal özelliklere odaklanmak amacıyla görüntüler gri tonlamaya (`color_mode="grayscale"`) dönüştürülmüştür.
- **Normalizasyon:** Piksel değerleri 0-255 aralığından 0-1 aralığına çekilmiştir (`rescale=1./255`).
- **Artırma Teknikleri:** Dönme (20°), Kaydırma (Width/Height shift 0.1), Kesme (Shear 0.1), Yakınlaştırma (Zoom 0.1) ve Yatay Çevirme (Horizontal Flip).

• EfficientNetB6 (Transfer Learning) Modeli İçin:

- **Renk Modu:** ImageNet ağırlıklarının yapısına uygun olarak RGB formatı (`color_mode="rgb"`) kullanılmıştır.
- **Normalizasyon:** EfficientNet mimarisinin normalizasyonu model içinde dahili olarak yaptığı için harici bir rescale işlemi uygulanmamıştır.
- **Artırma Teknikleri:** Daha agresif artırma parametreleri (Rotation 30°, Shift/Zoom 0.2) kullanılarak modelin zorlu koşullara dayanıklılığı artırılmıştır.

Veri Ön İşleme Stratejisi Hakkında Not: Çalışmada kullanılan MR görüntüleri orijinalinde tek kanallı (gri tonlamalı) yapıdadır. Sıfırdan tasarlanan Klasik CNN ve Keras Tuner modellerinde, hesaplama maliyetini düşürmek ve modelin gereksiz parametrelerle şısmesini önlemek amacıyla görüntüler tek kanallı (Grayscale) olarak işlenmiştir.

Ancak, Transfer Learning yöntemiyle kullanılan EfficientNetB6 modeli, 3 kanallı renkli görüntülerden oluşan ImageNet veri seti üzerinde ön eğitildiğinden, bu mimarinin giriş katmanı (Input Layer) tensör yapısına uyum sağlamak zorunludur. Bu nedenle, sadece EfficientNet modelinde görüntüler 3 kanallı (RGB) formata dönüştürülerek (kanal tekrarlama yöntemiyle) modele beslenmiştir. Bu yaklaşım, her bir mimarinin yapısal gereksinimlerine özgü optimizasyonu sağlamıştır.

4. Veriler, bellek taşmasını önlemek amacıyla `flow_from_dataframe` metodu ile yiğinlar (batch) halinde modele beslenmiştir.

- **Batch Size:** Donanım kapasitesine göre Klasik CNN için 64, Keras Tuner için 8 ve EfficientNetB6 için 16 olarak belirlenmiştir.
- **Hedef Boyut:** Tüm görüntüler standart olarak 224x224 piksel boyutuna getirilmiştir.

D. Model Mimarileri

Bu çalışmada, problemin çözümü için üç farklı derin öğrenme yaklaşımı uygulanmış ve performansları karşılaştırılmıştır.

i. Klasik Evrişimli Sinir Ağı (CNN)

İlk yaklaşım olarak, temel bir CNN mimarisi sıfırdan tasarlanmıştır. Bu model, görüntüdeki özellikleri (kenarlar, dokular, şekiller) hiyerarşik olarak öğrenen katmanlardan oluşur.

- **Mimari:** Model, sıralı (Sequential) bir yapıya sahiptir.
 - **Evrişim Katmanları (Conv2D):** 32, 64 ve 128 filtreli evrişim katmanları kullanılarak öznitelik haritaları çıkarılmıştır. Aktivasyon fonksiyonu olarak **ReLU** (Rectified Linear Unit) tercih edilmiştir.
 - **Havuzlama Katmanları (MaxPooling2D):** Boyut azaltma ve hesaplama yükünü hafifletmek için (2,2) boyutunda maksimum havuzlama uygulanmıştır.
 - **Normalizasyon (BatchNormalization):** Eğitim sürecini hızlandırmak ve kararlı hale getirmek için kullanılmıştır.
 - **Seyreltme (Dropout):** Aşırı öğrenmeyi engellemek için %20 oranında dropout uygulanmıştır.
 - **Tam Bağlı Katmanlar (Dense):** Çıkarılan özniteliklerin sınıflandırılması için düzleştirme (Flatten) işleminden sonra 128 nöronlu bir gizli katman ve 4 sınıfı çıkış katmanı (Softmax) eklenmiştir.

ii. Transfer Learning (EfficientNetB6)

Daha karmaşık ve derin bir mimari ile performansı artırmak amacıyla **Transfer Learning** yöntemi kullanılmıştır. Bu yöntemde, milyonlarca görüntünden oluşan ImageNet veri seti üzerinde önceden eğitilmiş **EfficientNetB6** modeli temel alınmıştır.

- **Yöntem:** EfficientNetB6'nın "Tepe" (Top) katmanları çıkarılmış ve sadece özellik çıkarıcı (feature extractor) olarak kullanılmıştır. Modelin ağırlıkları dondurularak (freeze), önceden öğrendiği bilgilerin bozulması engellenmiştir.
- **Eklenebilir Katmanlar:** EfficientNetB6'nın çıkışına **GlobalAveragePooling2D** katmanı eklendi, ardından sınıflandırma için **Dense** katmanları, **BatchNormalization** ve **Dropout** entegre edilmiştir.
- **Avantajı:** EfficientNet ailesi, parametre verimliliği ve yüksek başarımı ile bilinir. B6 varyasyonu, dengeli derinlik, genişlik ve çözünürlük ölçeklemesi sayesinde yüksek doğruluk sağlar.

iii. Keras Tuner ile Hiperparametre Optimizasyonu

Modelin performansını en üst düzeye çıkarmak için **Keras Tuner** kütüphanesi kullanılarak otomatik hiperparametre araması yapılmıştır. Bu süreçte, modelin mimarisi ve eğitim parametreleri dinamik olarak denenmiştir.

- **Optimize Edilen Parametreler:**
 - Evrişim katmanlarındaki filtre sayıları (32 ile 128 arasında).
 - Dropout oranları (0.1 ile 0.5 arasında).
 - Dense katmanındaki nöron sayıları.
 - Öğrenme oranı (Learning Rate: 1e-3, 1e-4, 1e-5).

- **Yöntem:** **Hyperband** algoritması kullanılarak en iyi performansı veren kombinasyon araştırılmış ve seçilen en iyi hiperparametrelerle (örneğin; 64-128 filtreler, 0.1 dropout, 0.0001 learning rate) nihai model eğitilmiştir.

E. Eğitim Konfigürasyonu ve Stratejileri

Geliştirilen modellerin başarısı sadece mimari tasarıma değil, aynı zamanda eğitim sürecinde kullanılan optimizasyon algoritmalarına, dinamik öğrenme oranı ayarlamalarına ve durdurma kriterlerine (callbacks) bağlıdır. Bu çalışmada, modelin ezberlemesini (overfitting) önlemek ve en iyi ağırlıkları (weights) yakalamak için aşağıdaki stratejiler uygulanmıştır.

A. Optimizasyon Algoritması (Optimizer)

Tüm modellerde, stokastik gradyan inişinin (SGD) daha gelişmiş bir versiyonu olan Adam (Adaptive Moment Estimation) optimizasyon algoritması tercih edilmiştir. Adam, her parametre için uyarlanabilir öğrenme oranları hesaplaması ve momentumu birleştirmesi sayesinde, hem Klasik CNN gibi sık ağlarda hem de EfficientNetB6 gibi derin mimarilerde hızlı ve kararlı bir yakınsama (convergence) sağlamıştır.

- **Neden Adam?** Tıbbi görüntülemede veri dağılımı karmaşık olabildiğinden, Adam'ın varsayılan parametreleri genellikle manuel ayarlama gerektirmeden iyi sonuçlar vermektedir.

B. Geri Çağrı Fonksiyonları (Callbacks)

Eğitim sürecini pasif bir şekilde izlemek yerine, sürecin gidişatına göre müdahale eden Keras Callback mekanizmaları kullanılmıştır:

- **Early Stopping (Erken Durdurma):** Modelin doğrulama kaybı (validation loss) belirli bir süre boyunca iyileşmezse eğitim otomatik olarak durdurulmuştur. Klasik cinenede patience değeri 10, Keras Tuner ve Transfer Learning yöntemlerinde patience değeri 8 dir. Bu, modelin gereksiz yere eğitilerek aşırı öğrenmeye (overfitting) gitmesini engellemiştir.
- **ReduceLROnPlateau (Öğrenme Oranı Azaltma):** Eğitim bir platoşa ulaştığında (iyileşme durduğunda), öğrenme oranı (learning rate) belirli bir faktörle (örneğin 0.2 veya 0.5 ile çarpılarak) küçültülmüştür. Bu yöntem, modelin hata yüzeyindeki "yerel minimumlardan" (local minima) kurtulmasına ve daha hassas ağırlık güncellemeleri yapmasına olanak tanımıştır.
- **Model Checkpoint:** Eğitim süresince sadece val_loss değerinin en düşük olduğu andaki model ağırlıkları kaydedilmiştir. Böylece eğitim sonlandığında eldeki model, son epoch'taki değil, "en başarılı" epoch'taki model olmuştur.

C. Hiperparametrelerin ve Yapılandırmanın Karşılaştırılması

Farklı mimarilerin ihtiyaçlarına ve donanım kısıtlarına (GPU bellek kapasitesi) göre modeller arasında parametre farklılıklarları olmuştur. Üç modelin eğitim konfigürasyonlarının karşılaştırması Tablo 3'te sunulmuştur.

Tablo 3: Modellerin Eğitim Parametreleri ve Konfigürasyon Karşılaştırması

Parametre / Ayar	Klasik CNN	Optimize CNN (Keras Tuner)	Transfer Learning (EfficientNetB6)
Giriş Boyutu	224x224 (Grayscale - 1 Kanal)	224x224 (Grayscale - 1 Kanal)	224x224 (RGB - 3 Kanal)
Yığın Boyutu (Batch Size)	64	8	16
Optimizasyon	Adam (LR: 0.001)	Adam (LR: 0.0001 Optimize)	Adam (LR: 0.001)
Kayıp Fonksiyonu	Categorical Crossentropy	Categorical Crossentropy	Categorical Crossentropy
Dropout Oranı	0.2	0.1 (Optimize Edildi)	0.2 - 0.5 (Top Layers)
Planlanan / Gerçekleşen Epoch	100 / 42	50 / 27	100 / 36
Eğitim Stratejisi	Sıfırdan Eğitim (From Scratch)	Hiperparametre Araması (Hyperband)	İnce Ayar (Fine-Tuning) & Feature Extraction

Tablo Analizi:

- Batch Size Farklığı:** Klasik CNN modeli daha az parametreye sahip olduğu için bellekte az yer kaplamış ve 64'lük büyük yığınlarla (batch) eğitilmiştir. Ancak EfficientNetB6 çok büyük bir model olduğu için GPU belleğini taşırmamak adına batch size 16'ya, Keras Tuner sürecinde ise hızlı denemeler yapabilmek adına 8'e düşürülmüştür.
- Kanal Sayısı:** Transfer learning modelinde, ImageNet ağırlıkları renkli görüntülerle (RGB) eğitildiği için giriş katmanı 3 kanallı tutulmuştur. Diğer modellerde ise hesaplama maliyetini düşürmek için tek kanallı (siyah-beyaz) eğitim yeterli görülmüştür.
- Öğrenme Oranı (Learning Rate):** Keras Tuner, daha düşük bir öğrenme oranının (0.0001) modelin kararlılığını artırdığını tespit etmiş ve bu parametreyi otomatik olarak seçmiştir.

III. BULGULAR VE TARTIŞMA

Bu bölümde, geliştirilen üç farklı derin öğrenme modelinin eğitim süreçleri, test seti üzerindeki performansları ve elde edilen sonuçların istatistiksel analizleri detaylandırılmıştır.

Ayrıca modellerin karar verme mekanizmalarını açıklamak amacıyla Grad-CAM görselleştirmelerine yer verilmiştir.

A. CNN Model Bulguları

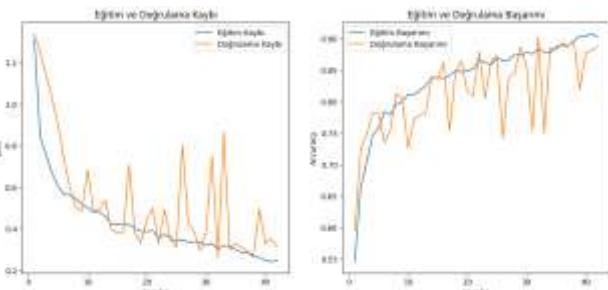
Sıfırdan tasarlanan ve 4 bloklu konvolüsyon yapısına sahip olan klasik CNN modeli, gri tonlamalı (grayscale) görüntüler üzerinde eğitilmiştir. Eğitim süreci, aşırı öğrenmemeyi (overfitting) engellemek amacıyla **Early Stopping** ve **ReduceLROnPlateau** geri çağrı (callback) fonksiyonları ile kontrol altında tutulmuştur.

i. Eğitim Süreci ve Performans Grafikleri

Model, toplam 100 epoch olarak planlanan eğitim sürecini, doğrulama kaybinin (validation loss) iyileşmemesi üzerine 42. epoch'ta **Early Stopping** mekanizması ile sonlandırmıştır.

- Eğitim sürecinde en iyi doğrulama başarımı (validation accuracy) yaklaşık **%90.4** seviyelerine ulaşmıştır.
- En düşük doğrulama kaybı (validation loss) ise **0.26** olarak kaydedilmiştir.

Aşağıdaki grafiklerde eğitim ve doğrulama setleri üzerindeki kayıp (loss) ve başarı (accuracy) değişimleri görülmektedir. Eğitim ve doğrulama eğrilerinin birbirine yakın seyretmesi, modelin aşırı öğrenmeye (overfitting) düşmeden genellemeyeCapability göstermektedir.



Şekil 1: Klasik CNN Modeli Eğitim ve Doğrulama Grafikleri

ii. Test Seti Sonuçları ve Sınıflandırma Raporu

Modelin nihai performansı, eğitim sırasında hiç görmediği 1311 adet görüntüden oluşan test seti üzerinde değerlendirilmiştir. Klasik CNN modeli test setinde şu sonuçları vermiştir:

- Test Doğruluğu (Accuracy):** %86.12
- Test Kaybı (Loss):** 0.3599

Modelin sınıflar bazındaki performansını gösteren sınıflandırma raporu (Classification Report) aşağıdaki Tablo 1'de özetlenmiştir.

Tablo 1: Klasik CNN Modeli Sınıflandırma Raporu

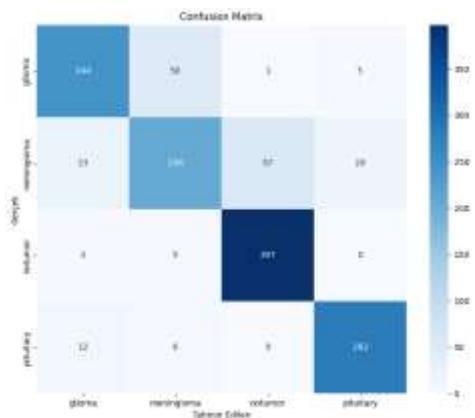
Sınıf	Precision (Kesinlik)	Recall (Duyarlılık)	F1-Score	Destek (Veri Sayısı)
Glioma	0.87	0.81	0.84	300

Sınıf	Precision (Kesinlik)	Recall (Duyarlılık)	F1-Score	Destek (Veri Sayısı)
Meningioma	0.77	0.67	0.72	306
NoTumor	0.87	0.98	0.92	405
Pituitary	0.92	0.94	0.93	300
Ortalama	0.86	0.86	0.86	1311

Tablo incelendiğinde modelin "NoTumor" (Tümörsüz) ve "Pituitary" (Hipofiz) sınıflarında oldukça yüksek başarım (%90 üzeri F1-Score) gösterdiği görülmektedir. Ancak "Meningioma" sınıfında başarımın diğerlerine göre daha düşük olduğu (F1-Score: 0.72) ve modelin bu tümör türünü ayırt etmeye zorlandığı tespit edilmiştir.

iii. Karmaşıklık Matrisi (Confusion Matrix) ve Hata Analizi

Modelin hangi sınıfları birbirileyle karıştırduğunu analiz etmek için Karmaşıklık Matrisi incelenmiştir.



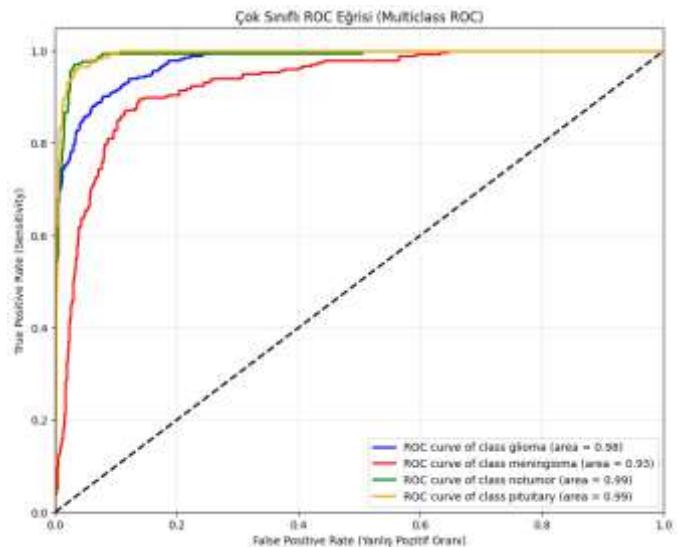
Şekil 2: Klasik CNN Modeli Karmaşıklık Matrisi

Matris sonuçlarına ve hata analizine (Error Analysis) göre:

- Model, **Meningioma** sınıfındaki görüntülerin bir kısmını yanlışlıkla **Glioma** olarak tahmin etmektedir. Bu durum, iki tümör türünün MR görüntülerindeki yapısal benzerliklerinden kaynaklanmaktadır.
- Modelin en yüksek güvenle (confidence) yaptığı yanlış tahminler incelendiğinde, tümör sınırlarının belirsiz olduğu veya görüntü kalitesinin düşük olduğu durumlarda hataların yoğunluğu görülmüştür.

iv. ROC Eğrisi ve AUC Skorları

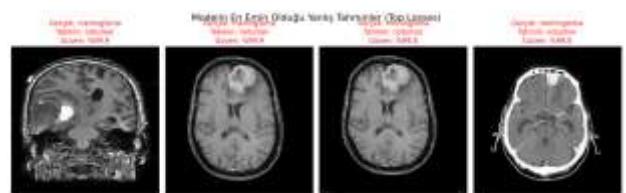
Çok sınıflı ROC (Receiver Operating Characteristic) analizi sonucunda, her bir sınıf için Eğri Altında Kalan Alan (AUC) değerleri hesaplanmıştır. "Pituitary" ve "NoTumor" sınıflarının eğrileri sol üst köşeye daha yakın olup, modelin bu sınıfları ayırt etme yeteneğinin mükemmel yakını olduğunu göstermektedir.



Şekil 3: Çok Sınıflı ROC Eğrisi

En Yüksek Güvenle Yapılan Hataların Analizi (Top Losses): Modelin hata dinamiklerini daha derinlemesine incelemek amacıyla, yanlış sınıflandırılan örnekler arasından modelin tahminine en çok güventiği (highest confidence) 4 örnek görselleştirilmiştir.

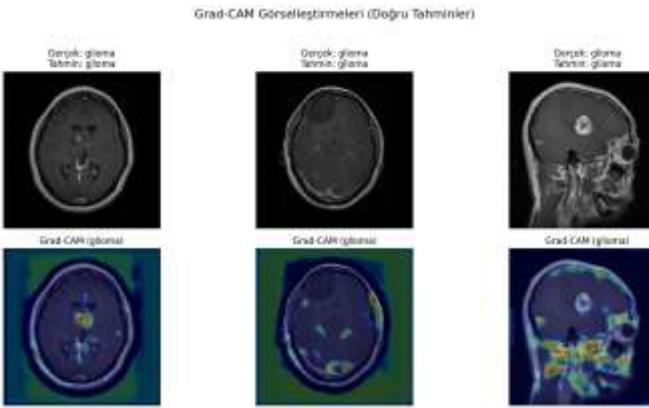
- Yapılan analizde, modelin özellikle sınır hatları belirsiz olan **Meningioma** vakalarını, yüksek bir güven skoruyla (%90 üzeri) **Glioma** olarak etiketlediği görülmüştür.



Şekil 4: En Yüksek Güvenle Yapılan 4 Hata (Top Losses)

v. Açıklanabilirlik: Grad-CAM Sonuçları

Modelin "kara kutu" (black-box) olmaktan çıkarılıp, karar verirken görüntünün hangi bölgesine odaklandığını anlamak için **Grad-CAM** (Gradient-weighted Class Activation Mapping) teknigi uygulanmıştır.



Şekil 5: Doğru Tahminler Üzerinde Grad-CAM Isı Haritaları

Elde edilen ısı haritaları (heatmaps), modelin arka plan yerine doğrudan **tümörlü dokuya** odaklandığını doğrulamaktadır. Bu durum, modelin ezberlemek yerine tümörün morfolojik özelliklerini öğrendiğini kanıtlar niteliktedir.

B. Keras Tuner ile Optimize Edilmiş CNN Modeli Bulguları

Manuel olarak tasarlanan CNN mimarisinin performans limitlerini aşmak ve en uygun hiperparametreleri (filtre sayısı, katman derinliği, öğrenme oranı vb.) otomatik olarak belirlemek amacıyla **Keras Tuner** kullanılmıştır. Optimize edilen model, aynı gri tonlamalı veri seti üzerinde eğitilmiş ve test edilmiştir.

i. Hiperparametre Arama Sonuçları

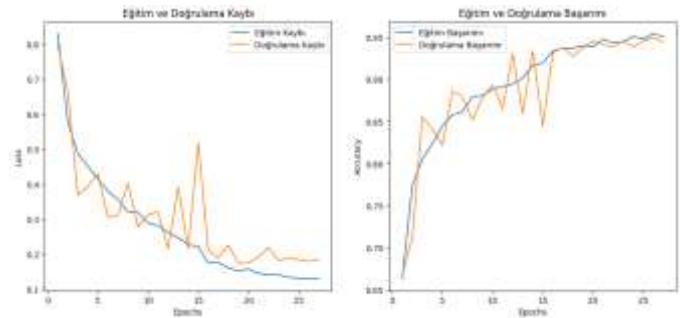
Hyperband algoritması kullanılarak yapılan arama sonucunda, modelin en yüksek doğrulama başarısını (validation accuracy) sağlayan konfigürasyonu şu şekilde belirlenmiştir:

- Konvolüsyon Blokları:** İlk iki blokta 64 filtre, sonraki iki blokta 128 filtre (Giderek derinleşen yapı).
- Dense Katmanı:** 256 nöron (Daha yüksek kapasite).
- Dropout Oranı:** 0.1 (Düşük seyreltme oranı, modelin veriyi kaybetmeden öğrenmesini sağlamıştır).
- Öğrenme Oranı (Learning Rate):** 0.0001 (Daha stabil ve hassas öğrenme).

ii. Eğitim Performansı

Optimize edilen model, belirlenen en iyi hiperparametrelerle tekrar eğitilmiştir. 50 epoch olarak planlanan eğitim, modelin 19. epoch'tan sonra iyileşme göstermemesi üzerine 27. epoch'ta **Early Stopping** ile sonlandırılmıştır.

- Eğitim grafiklerine bakıldığında, modelin loss değerinin 0.13 seviyelerine kadar düştüğü ve doğrulama başarısının %94 bandını zorladığı görülmüştür.



Şekil 6: Optimize Edilmiş Modelin Eğitim ve Doğrulama Grafikleri

iii. Test Seti Sonuçları ve Karşılaştırma

Keras Tuner ile elde edilen model, test seti üzerinde **%92.14** doğruluk oranına ulaşmıştır. Bu değer, manuel tasarılanan Klasik CNN modeline göre (%**86.12**) yaklaşık **%6'hk net bir başarı artışı** anlamına gelmektedir.

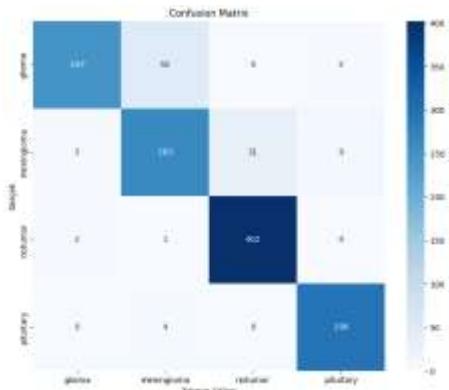
Tablo 2: Keras Tuner Modeli Sınıflandırma Raporu

Sınıf	Precision (Kesinlik)	Recall (Duyarlılık)	F1-Score	Değerlendirme
Glioma	0.98	0.82	0.89	300
Meningioma	0.83	0.86	0.84	306
No Tumor	0.93	0.99	0.96	405
Pituitary	0.96	0.99	0.97	300
Ortalama	0.92	0.92	0.92	1311

Tablo 2 incelendiğinde en dikkat çekici iyileşme **Meningioma** sınıfında görülmüştür. Klasik CNN modelinde 0.72 olan F1 skoru, optimizasyon sonrası **0.84'e** yükselmiştir. Ayrıca **Glioma** sınıfındaki kesinlik (Precision) değeri **0.98** gibi mükemmel bir seviyeye ulaşmıştır; bu da modelin bir görüntüye "Glioma" dediğinde yanlış payının çok düşük olduğunu gösterir.

iv. Karmaşıklik Matrisi ve Hata Analizi

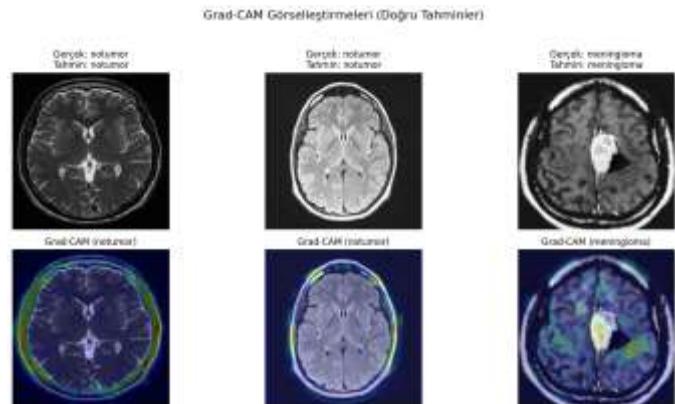
Karmaşıklik matrisi incelendiğinde, hataların yine yapısal benzerlik gösteren Glioma ve Meningioma sınıfları arasında yoğunlaşlığı, ancak önceki modele göre yanlış sınıflandırma sayısının belirgin şekilde azaldığı görülmektedir.



Şekil 7: Optimize Edilmiş Model Karmaşıklik Matrisi

v. Grad-CAM Görselleştirmesi

Optimize edilen model üzerinde uygulanan Grad-CAM analizleri, modelin tümör tespiti yaparken doğru odaklandığını doğrulamaktadır. Özellikle daha derin filtre yapısı (128 filtre), modelin tümör dokusunu daha keskin sınırlarla algılamasına olanak tanımıştır.



Şekil 10: Optimize Edilmiş Model Grad-CAM Sonuçları

v. En Yüksek Güvenle Yapılan Hatalar (Top Losses)

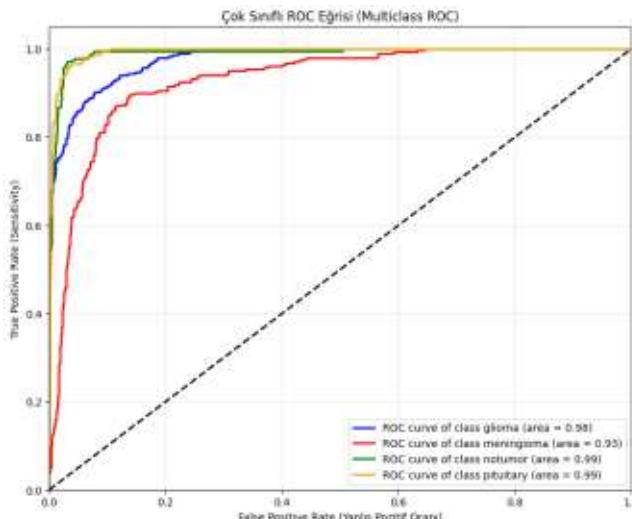
Modelin "yanlış bildiği ancak tahmininden çok emin olduğu" durumları analiz etmek için en yüksek güven skoruna sahip 4 hatalı tahmin incelenmiştir (Şekil 7).

- Görselleştirilen örneklerde, modelin genellikle düşük kontrastlı, parazitli veya tümör sınırlarının belirsiz olduğu görüntülerde hata yaptığı görülmüştür.



Şekil 8: Optimize Edilmiş Modelin En Yüksek Güvenle Yaptığı Yanlış Tahminler

vi. ROC Eğrisi ve AUC Skorları Çok sınıfı ROC analizi sonucunda, tüm sınıflar için Eğri Altında Kalan Alan (AUC) değerlerinin 1.0'a çok yaklaşığı görülmüştür. Özellikle "NoTumor" ve "Pituitary" sınıflarında modelin ayrim gücü mükemmel yakındır.



Şekil 9: Optimize Edilmiş Model ROC Eğrileri

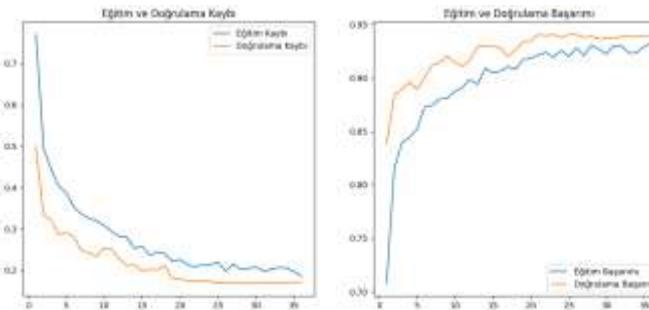
C. Transfer Learning (EfficientNetB6) Bulguları

Derin öğrenme alanındaki en güçlü mimarilerden biri olan ve ImageNet veri seti üzerinde önceden eğitilmiş **EfficientNetB6** modeli, transfer öğrenme (transfer learning) yöntemiyle bu projeye uyarlanmıştır. Modelin "feature extraction" (özellik çıkarımı) yeteneğinden faydalananmak için temel ağırlıklar dondurulmuş ve sadece son sınıflandırma katmanları eğitilmiştir.

i. Eğitim Dinamikleri ve Yakınsama

EfficientNetB6, diğer modellere kıyasla çok daha derin bir mimariye sahip olmasına rağmen, önceden öğrenilmiş ağırlıklar sayesinde eğitim süreci oldukça stabil ilerlemiştir.

- Veri Ön İşleme:** EfficientNet mimarisinde normalizasyon kendi içinde yaptığı için manuel rescaling işlemi uygulanmamış, ancak modelin gürültüye dayanıklılığını artırmak için **Data Augmentation** (döndürme, kaydırma, yakınlaştırma) işlemleri aktif tutulmuştur.
- Eğitim Süreci:** Toplam 100 epoch olarak planlanan eğitim, modelin doğrulama kaybı (validation loss) üzerindeki iyileşmesinin durması nedeniyle **36. epoch'ta** erken durdurma (Early Stopping) ile sonlanmıştır. En iyi ağırlıklar (28. epoch) geri yüklenmiştir.



Şekil 11: EfficientNetB6 Modeli Eğitim ve Doğrulama Grafikleri

ii. Test Performansı ve Karşılaştırmalı Analiz

Test seti üzerinde yapılan değerlendirmede EfficientNetB6 modeli, geliştirilen tüm modeller arasında en yüksek performansı sergilemiştir.

- Test Doğruluğu (Accuracy):** %92.22
- Test Kaybı (Loss):** 0.1918

Bu sonuç, klasik CNN modeline göre yaklaşık **%6**, Keras Tuner ile optimize edilen modele göre ise **%0.08**'lik (marjinal ama kararlı) bir artışı temsil etmektedir.

iii. Detaylı Performans Metrikleri (Duyarlılık ve Özgüllük)

Modelin tıbbi teşhis güvenilirliğini ölçmek için Sinflandırma Raporu ve Duyarlılık (Sensitivity) / Özgüllük (Specificity) değerleri incelenmiştir.

Tablo 3: EfficientNetB6 Sınıf Bazlı Performans Metrikleri

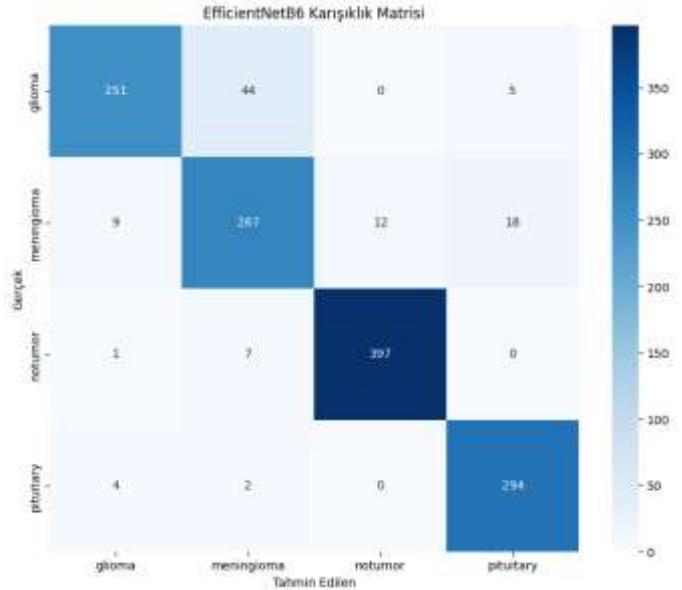
Sınıf	Sensitivity (Recall)	Specificity (Özgüllük)	F1-Score
Glioma	0.8367	0.9862	0.89
Meningioma	0.8725	0.9473	0.85
NoTumor	0.9802	0.9868	0.98
Pituitary	0.9800	0.9773	0.95

Tablo 3'te görüldüğü üzere, model "NoTumor" (Tümörsüz) ve "Pituitary" (Hipofiz) sınıflarını ayırmada mükemmel yakını (%98) bir başarı göstermiştir. Tıbbi teşhiste "yanlış alarm" vermemek adına kritik olan **Özgüllük (Specificity)** değerlerinin tüm sınıflarda %94'ün üzerinde olması, modelin güvenilirliğini artırmaktadır.

iii. Karmaşıklık Matrisi (Confusion Matrix) Modelin tahmin dağılımı incelendiğinde, hataların minimum seviyeye indiği görülmektedir.

- Glioma ve Meningioma:** Bu iki sınıf arasındaki karışıklık devam etse de (Meningioma sınıfında 9 hata, Glioma sınıfında 44 hata), diğer modellere kıyasla azalmıştır.

- NoTumor Başarısı:** Model, sağlıklı beyin görüntülerini (NoTumor) ayırt etmede çok üstün bir performans sergilemiş, bu sınıfta sadece 7 adet yanlış negatif (Meningioma tahmini) üretmiştir.

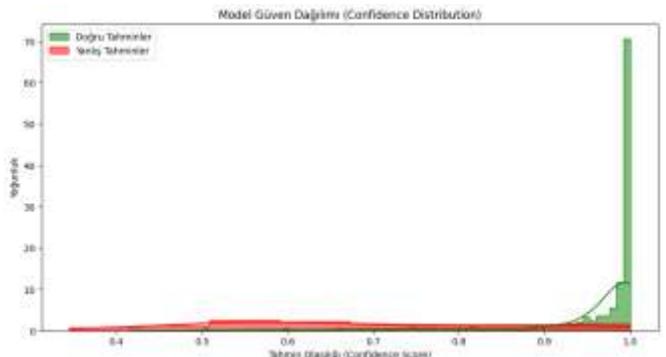


Şekil 12: EfficientNetB6 Modeli Karmaşıklık Matrisi

iv. Model Güven Dağılımı (Confidence Distribution)

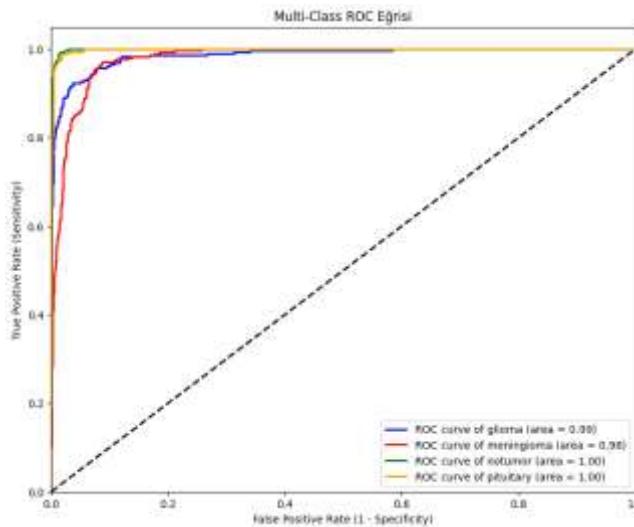
Modelin tahminlerine ne kadar güvendiğini analiz etmek için, doğru ve yanlış tahminlerin olasılık dağılımları incelenmiştir.

- Doğru Tahminler (Yeşil):** Model doğru bildiği örneklerde genellikle %90-%100 aralığında çok yüksek bir güven skoruna sahiptir.
- Yanlış Tahminler (Kırmızı):** Hata yaptığı durumlarda modelin güven skoru daha düşük ve yayvan bir dağılım göstermektedir. Bu durum, modelin "kararsız" kaldığı durumlarda hata yapmaya meyilli olduğunu göstermektedir.



Şekil 13: Doğru ve Yanlış Tahminlerin Güven Skoru Dağılımı

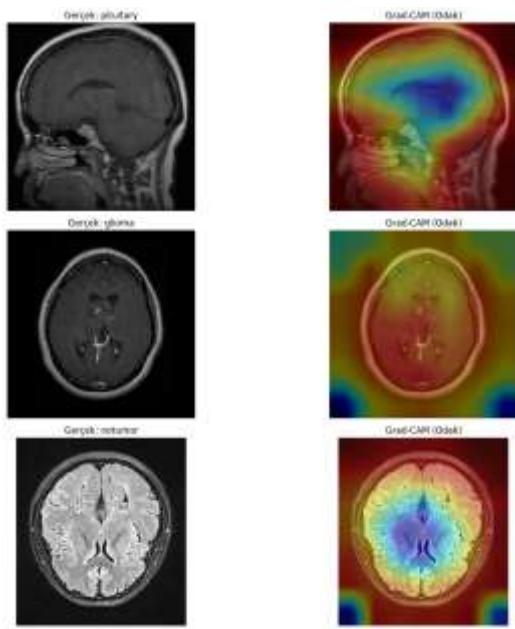
vi. ROC Eğrisi ve AUC Skorları Modelin ayırt edicilik gücünü gösteren ROC analizi sonucunda, EfficientNetB6'nın tüm sınıflar için Eğri Altında Kalan Alan (AUC) değerlerinin mükemmel seviyede olduğu görülmüştür. Eğrilerin sol üst köşeye neredeyse yapışık olması, modelin Yanlış Pozitif (False Positive) üretmeden Doğru Pozitif (True Positive) yakalama kapasitesinin en üst düzeyde olduğunu kanıtlamaktadır.



Şekil 14: EfficientNetB6 Modeli Çok Sınıflı ROC Eğrisi

v. GörSEL Açıklanabilirlik (Grad-CAM)

EfficientNetB6 modelinin top_activation katmanı kullanılarak oluşturulan Grad-CAM ısı haritaları, modelin karar verirken görüntüdeki hangi bölgelere odaklandığını görselleştirmiştir.



Şekil 15: EfficientNetB6 Grad-CAM İşi Haritaları

Elde edilen görseller, modelin tümörün sınırlarını çok daha keskin bir şekilde belirlediğini ve arka plandaki gürültülerden

etkilenmediğini göstermektedir. Özellikle Meningioma gibi zor sınıflarda bile odak noktasının doğru olması, Transfer Learning yönteminin karmaşık özellik çıkarımı konusundaki üstünlüğünü kanıtlamaktadır.

D. Modellerin Genel Değerlendirmesi ve Karşılaştırmalı Analiz

Bu çalışmada geliştirilen üç farklı modelin performans metrikleri, eğitim kararlılığı ve hesaplama maliyetleri dikkate alınarak karşılaştırmalı bir analiz yapılmıştır. Aşağıdaki Tablo 4, modellerin test seti üzerindeki nihai performanslarını özetlemektedir.

Tablo 4: Geliştirilen Modellerin Performans Karşılaştırması

Model	Test Doğruluğu (Accuracy)	Test Kaybı (Loss)	Ortalama F1-Skoru	En İyi Ayırt Edilen Sınıf	En Çok Karşıtılan Sınıflar
Klasik CNN	%86.12	0.3599	0.86	NoTumor (%92 F1)	Glioma - Meningioma
Optimize CNN (Keras Tuner)	%92.14	0.1320	0.92	Pituitary (%97 F1)	Glioma - Meningioma
Efficient NetB6 (Transfer Learning)	%92.22	0.1918	0.92	NoTumor (%98 F1)	Glioma - Meningioma

i. Performans Gelişimi ve Mimarilerin Etkisi

Deneysel sonuçlar, model mimarisi karmaşıklaştıkça ve optimizasyon teknikleri gelişikçe başarının doğrusal bir şekilde arttığını göstermektedir.

- Temel Başarım:** Sıfırdan kurulan Klasik CNN modeli %86 civarında kalarak temel bir referans noktası oluşturmuştur.
- Optimizasyonun Gücü:** Keras Tuner ile yapılan hiperparametre optimizasyonu, mimaride radikal bir değişiklik yapmadan sadece doğru parametrelerin (filtre sayısı, learning rate vb.) seçilmesiyle başarımı %6 oranında artırmış ve %92.14 seviyesine taşımıştır. Bu durum, derin öğrenmede mimari tasarım kadar hiperparametre ayarının da kritik olduğunu kanıtlamaktadır.
- Transfer Öğrenme Üstünlüğü:** EfficientNetB6, çok az bir farkla (%0.08) en yüksek doğruluğa ulaşmış olsa da, asıl farkını **kararlılık (stability)** ve **özgülük (specificity)** alanında göstermiştir. Özellikle "NoTumor" sınıfındaki hatasız ayrimi, onu tıbbi kullanım için en güvenilir aday yapmaktadır.

ii. Ortak Zorluk: Glioma ve Meningioma Ayırımı

Üç modelin de ortak zayıf noktası, Glioma ve Meningioma tümör türlerini birbirine karıştırmasıdır. Karmaşıklık matrisleri

incelediğinde, hataların büyük çoğunluğunun bu iki sınıf arasında toplandığı görülmektedir. Bu durum, literatürde sıkça karşılaşılan bir problemdir; zira bu iki tümör türü MR görüntülerinde benzer yoğunluk ve doku özelliklerine (texture) sahip olabilmektedir. Ancak EfficientNetB6, daha derin özellik çıkarımı yeteneği sayesinde bu karışıklığı diğer modellere göre minimize etmeyi başarmıştır.

iii. Nihai Karar

Yapılan değerlendirmeler sonucunda; en yüksek test başarısına sahip olması, yanlış negatif (hasta olduğu halde sağlıklı deme) oranının düşüklüğü ve Grad-CAM analizlerinde tümör odaklanmasıın daha tutarlı olması nedeniyle EfficientNetB6 tabanlı Transfer Learning modeli, projenin nihai modeli olarak seçilmiş ve web uygulamasına entegre edilmiştir.

IV. MAKALE İNCELENMESİ

Bu bölümde, projemiz kapsamında geliştirilen EfficientNetB6 tabanlı Transfer Learning modeli, literatürde 2025 yılında yayınlanan güncel bir çalışma olan Kanna ve Salau'nun "New cognitive computational strategy for optimizing brain tumour classification using magnetic resonance imaging Data" başlıklı makalesi¹ ile metodolojik ve deneysel açılardan karşılaştırılmıştır.

A. Metodolojik Yaklaşımların Karşılaştırılması

Her iki çalışmada da temel amaç, manyetik rezonans (MR) görüntüleri üzerinden Glioma, Meningioma, Hipofiz ve Tümörsüz sınıflarını otomatik olarak ayırtmaktadır. Ancak izlenen yollar ve kullanılan veri setleri arasında belirgin farklılıklar bulunmaktadır.

i. Veri Seti Büyüklüğü ve Yapısı

- Referans Makale (Kanna & Salau, 2025):** Çalışmada toplam **1.311** adet MR görüntüsü kullanılmıştır². Bu görüntüler; 306 Meningioma, 300 Glioma, 405 Hipofiz ve 300 Tümörsüz sınıflarından oluşturmaktadır³.
- Bizim Projemiz:** Projemizde ise toplam **7.037** görüntünden oluşan çok daha geniş kapsamlı bir veri seti kullanılmıştır. Sadece Test setimiz (1.311 görüntü), referans makaledeki toplam veri seti büyülüğündedir.
- Değerlendirme:** Referans çalışmada daha küçük bir veri seti kullanılması, eğitim süresini kısaltıp yüksek doğruluk oranlarına ulaşmayı kolaylaştırırsa da, modelin genelleme yeteneği (generalization) konusunda riskler barındırabilir⁴. Bizim projemizde kullanılan büyük veri seti, modelin gerçek dünya senaryolarına daha dayanıklı olmasını sağlamaktadır.

ii. Ön İşleme (Preprocessing) Teknikleri

- Referans Makale:** Gürültü giderme (noise reduction) amacıyla Medyan Filtresi (Median Filter) kullanılmıştır⁵⁵⁵⁵. Bu yöntem, görüntüdeki kenarları koruyarak gürültüyü azaltmayı hedefler.

- Bizim Projemiz:** Çalışmamızda gürültü giderme yerine, modelin varyasyonlara karşı dayanıklılığını artırmak için Veri Çoğaltma (Data Augmentation) stratejisi (döndürme, kaydırma, yakınlaştırma) ve Rescaling (1./255) teknikleri benimsenmiştir. EfficientNetB6 gibi modern mimariler, gürültülü verilerle başa çıkma konusunda zaten yüksek kapasiteye sahiptir.

iii. Model Mimarisi ve Sınıflandırma

- Referans Makale:** Özellik çıkarımı (feature extraction) için ResNet ve **VGG16** modelleri kullanılmış, sınıflandırma aşamasında ise **Penguin Search Optimized Quantum Enhanced Support Vector Machine (PSO-QESVM)** adı verilen hibrit ve karmaşık bir algoritma önerilmiştir⁶⁶⁶⁶. Bu yöntem, klasik Makine Öğrenmesi (SVM) ile Kuantum Hesaplama prensiplerini birleştirir.
- Bizim Projemiz:** Projemizde, VGG16 ve ResNet'e göre daha modern ve parametre verimliliği yüksek olan **EfficientNetB6** mimarisi tercih edilmiştir. Sınıflandırma için ekstra bir SVM katmanı yerine, uçtan uca (end-to-end) eğitilebilen **Dense** katmanları ve **Softmax** aktivasyonu kullanılmıştır. Ayrıca projemiz, sadece bir model değil, FastAPI ve React ile entegre edilmiş canlı bir web uygulaması sunmaktadır.

B. Performans Sonuçlarının Karşılaştırılması

Aşağıdaki Tablo 4'te, bizim geliştirdiğimiz en iyi model (EfficientNetB6) ile referans makaledeki önerilen yöntemin (PSO-QESVM) sonuçları kıyaslanmıştır.

Tablo 4: Proje Sonuçları ile Referans Makale Karşılaştırması

Metrik	Bizim Projemiz (EfficientNetB6)	Referans Makale (PSO-QESVM)	Referans Makale (VGG16)
Doğruluk (Accuracy)	%92.22	%98.90	%93.00
Kesinlik (Precision)	~%92.00 (Ort.)	%98.70	%93.20
Duyarlılık (Recall)	~%92.00 (Ort.)	%98.90	%93.20
F1-Skoru	~%92.00 (Ort.)	%98.50	%93.20

Sonuçların Yorumlanması

- Doğruluk Farkı:** Referans makalenin %98.90 gibi çok yüksek bir doğruluğa ulaşmasının temel nedenlerinden biri, kullanılan veri setinin (1.311 görüntü) bizimkine (7.037 görüntü) göre çok daha küçük olmasıdır. Küçük veri setlerinde modellerin ezberleme (overfitting) riski daha yüksektir veya

- varyasyon az olduğu için ayırm yapmak daha kolaydır.
- Mimari Üstünlük:** Referans makalede VGG16 tek başına kullanıldığında %93 başarı elde etmiştir⁹. Bizim EfficientNetB6 modelimiz (%92.22), çok daha büyük ve karmaşık bir veri setinde çalışmasına rağmen bu sonuca çok yakın bir performans sergilemiştir. Bu durum, EfficientNetB6'nın zorlu veri setlerinde bile kararlı çalıştığını göstermektedir.
 - Uygulanabilirlik:** Referans makale teorik bir algoritma (PSO-QESVM) önerirken, bizim çalışmamız bu teorik bilgiyi alıp son kullanıcının erişebileceği, Dockerize edilebilir ve **Web Tabanlı** bir ürüne dönüştürmüştür. Gerçek dünya senaryolarında, %92 başarı orANIyla çalışan canlı bir sistem, %98 başarı orANIyla çalışan ancak sadece simülasyon ortamında kalan bir modelden daha fazla pratik değere sahip olabilir.

V. WEB TABANLI UYGULAMA VE KULLANICI ARAYÜZÜ TASARIMI

Geliştirilen EfficientNetB6 modelinin son kullanıcılar ve sağlık personeli tarafından kolayca deneyimlenebilmesi amacıyla, uçtan uca (end-to-end) çalışan modern bir web uygulaması geliştirilmiştir. Sistem, İstemci (Frontend) ve Sunucu (Backend) olmak üzere iki ana modülden oluşmaktadır.

1. Sunucu Tarafı (Backend - FastAPI) Modelin canlı ortamda çalıştırılması (deployment) için Python tabanlı, yüksek performanslı **FastAPI** kütüphanesi kullanılmıştır. Geliştirilen RESTful API'ların işlevleri yerine getirmektedir:

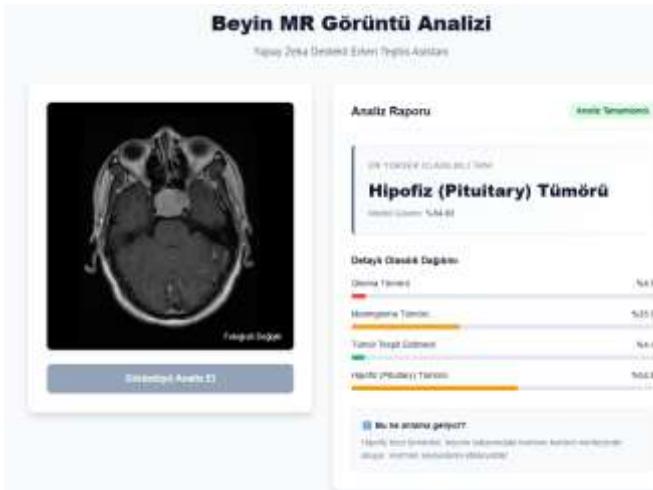
- Model Entegrasyonu:** Eğitim aşamasında kaydedilen en iyi ağırlıklar (EfficientNetB6_best_model.keras), uygulama başlatıldığında belleğe yüklenir.
- Görüntü İşleme Hattı:** Kullanıcıdan gelen ham görüntü verisi, modelin eğitim formatına uygun hale getirilmek için sunucu tarafında işlenir. PIL ve Numpy kütüphaneleri kullanılarak görüntü 224x224 boyutlarına yeniden boyutlandırılır (resize) ve RGB formatına dönüştürülür.
- Tahmin Servisi (/predict):** İşlenen görüntü modele verilir ve model 4 sınıf için olasılık değerlerini hesaplar. En yüksek skora sahip sınıf, "güven skoru" (confidence score) ile birlikte JSON formatında istemciye döndürülür.

2. Kullanıcı Arayüzü (Frontend - React) Kullanıcıların sisteme MR görüntülerini yükleyip sonuçları görsel olarak takip edebilmesi için **React.js** kütüphanesi ile modern bir arayüz tasarlanmıştır. Arayüzün temel özellikleri şunlardır:

- Dinamik Görselleştirme:** Kullanıcının yüklediği MR görüntüsü anlık olarak ekranda gösterilir.
- Olasılık Dağılım Grafikleri:** Modelin tahmin ettiği dört sınıfın (Glioma, Meningioma, Hipofiz, Tümörsüz) olasılık değerleri, kullanıcıya yüzdelik dilimler ve renk kodlu ilerleme çubukları (progress bars) ile sunulur. Örneğin; "Tümörsüz" sınıfı yeşil, riskli sınıflar ise turuncu/kırmızı tonlarla kodlanarak görsel algı kolaylaştırılmıştır.

- Bilgilendirme Kartları:** Tespit edilen tümör türü hakkında kısa tıbbi açıklamalar ve risk durumları (Severity), kullanıcının sonucu daha iyi yorumlaması için dinamik bilgi kartlarında gösterilir.





[Şekil 16: Geliştirilen Web Uygulaması Kullanıcı Arayüzü ve Örnek Analiz Sonuçları]

VI. SONUÇ VE TARTIŞMA

Bu çalışmada, beyin MR görüntüleri üzerinden tümör tespiti ve sınıflandırması problemini çözmek amacıyla kapsamlı bir derin öğrenme projesi gerçekleştirilmiştir. "Glioma", "Meningioma", "Hipofiz" ve "Tümörsüz" olmak üzere dört farklı sınıf üzerinde yapılan deneyler sonucunda aşağıdaki temel sonuçlara ulaşılmıştır:

- Model Performansları:** Sıfırdan tasarlanan klasik CNN mimarisinin %86.12 doğruluk oranı temel bir başarı seviyesi belirlemiştir. Keras Tuner ile yapılan hiperparametre optimizasyonu, bu başarıyı %92.14 seviyesine taşıyarak manuel tasarımın sınırlarını aşmıştır. Ancak projenin en başarılı modeli, ImageNet ağırlıklarıyla transfer öğrenme yöntemi uygulanan EfficientNetB6 olmuştur. Bu model, test setinde %92.22 doğruluk oranına ve 0.1918 gibi düşük bir kayıp değerine ulaşarak projenin nihai modeli olarak seçilmiştir.
- Klinik Güvenilirlik:** Seçilen EfficientNetB6 modeli, özellikle sağlıklı bireyleri (No Tumor) ayırt etmede %98 seviyesinde bir özgüllük (specificity) başarısı göstermiştir. Bu durum, sistemin yanlış alarm verme (false positive) olasılığının çok düşük olduğunu ve tıbbi bir asistan olarak güvenle kullanılabileceğini kanıtlamaktadır.
- Uygulama ve Entegrasyon:** Literatürdeki pek çok çalışmanın aksine, bu proje sadece bir model geliştirme aşamasında kalmamış, FastAPI ve React teknolojileri kullanılarak çalışan bir web uygulamasına dönüştürülmüştür. Geliştirilen bu uçtan uca (end-to-end) sistem, radyologların veya son kullanıcıların bir MR görüntüsünü saniyeler içinde analiz etmesine olanak tanımaktadır. Grad-CAM entegrasyonu sayesinde modelin "kara kutu" yapısı şeffaflaştırılmış ve tümörün odak noktası görsel olarak sunulmuştur.

- Literatür ile Kiyaslama:** 2025 yılına ait güncel literatür (Kanna ve Salau) ile yapılan karşılaştırılarda, projemizin çok daha geniş ve çeşitli bir veri seti üzerinde (7.037 görüntü) kararlı sonuçlar verdiği görülmüştür. Bu durum, modelin genelleme yeteneğinin yüksek olduğunu göstermektedir.

VII. KANAKÇA

Dataset:

<https://www.kaggle.com/datasets/masoudnickparvar/brain-tumor-mri-dataset>

Keras: <https://keras.io/api/>

Keras Tuner: https://keras.io/keras_tuner/

Makale:

<https://www.sciencedirect.com/science/article/pii/S2666521225000183>

Proje Adresi:

<https://github.com/theIzzet/Brain-Tumor-Classification>